

孙英博

电话: 17724605660

邮箱: charlessun0409@163.com



教育背景

2018.09-2019.12	英国诺丁汉大学	统计学	研究生
2014.09-2018.07	西北大学	应用统计学	本科

职业摘要

数据科学与机器学习算法工程师，5年+经验，专注于通过算法优化与数据建模驱动业务价值。擅长构建高精度预测模型（XGBoost/深度学习）及可解释性方案（SHAP），主导过工业制造、新能源、金融、互联网等领域的AI项目，平均提升效率15%+。具备联邦学习、端到端产品开发及跨行业解决方案设计能力，致力于通过数据智能解决复杂业务问题，适配金融、医疗、互联网等多领域场景。此外，拥有大模型技术研发与应用经验，包括基于LangChain框架的问答系统、RAG知识检索及自动合规检查等项目，推动企业智能化转型。

关键技能

- 机器学习算法：XGBoost、GBDT、RF、SVM、KNN、KMeans
- 深度学习框架：PyTorch、CNN、RNN、LSTM、Transformer、GAN
- 数据分析工具：Python (Pandas、Scikit-learn)、SQL、Tableau、TempoBI
- 大模型技术：Prompt Engineering、RAG、Agent 框架 (LangChain、Dify)
- 其他：FastAPI、联邦学习、SHAP 模型解释性

核心工作经历

2023.04-2024.12 | TCL 格创东智 | 数据智能产品部 | 高级算法工程师

【算法开发】利用 fastAPI 与前后端进行交互

1. 零代码机器学习平台

- 设计特征工程与建模节点，支持20+模型（回归/分类/聚类），缩短建模时间90%。
- 开发自动更新机制，使模型适应新数据，预测准确性提升10%

2. 良率提升系统 (YMS)

- 根因分析：利用 SHAP 方法解释模型预测，开发宏观/微观特征重要性功能；支持 PCA、相关性分析、树模型(XGBoost、GBDT、RF)特征重要性等方法。
- 大模型问答机器人开发：基于大模型技术（包括 Prompt 设计与 Agent 框架），构建问答机器人系统，支持自然语言查询生产数据（如：查询某年某月某产品的良率、产量；查询机器操作程序等），实现生产数据的实时反馈与智能问答，提升现场决策效率。

3. 企业知识库检索系统(RAG)

- 知识库构建：采集企业规章与法规文件，OCR 解析后进行分块 (Chunking) 和文本清洗，Embedding 后存 Milvus 向量数据库。
- RAG 知识检索与问答：结合向量检索（采用 BM25 与语义匹配算法）与 LangChain 框架调用开源大模型进行问答生成，实现基于 RAG 框架的高效知识召回与答案生成。
- 自动合规检查：通过 API 接口和前端 UI 提供自然语言查询服务，并利用规则引擎与自动化审核模块对企业文档进行实时合规性检查和风险识别。

【项目跟进】

- 电芯容量预测 (锂电池)：提取153个关键特征，构建电芯容量预测模型 (MAPE 0.5%， R^2 99%)，缩减检测时间20%。实现企业（天能锂电、赣锋锂电、亿纬锂电）
- 时代新材虚拟量测 (新材料)：构建刚度与压缩高预测模型，分类模型漏检率<5%，回归模型误差达标率90%+。
- 锦江氧化铝项目 (化工)：构建云端数据智能平台，优化溶出工序控制精度，实现无人化先进控制。

2022.05-2023.04 | 牛津（海南）区块链研究院 | 密码实验室 | 算法研究员

1. 联邦学习技术研究

- 完成 4 项横向/纵向联邦学习实验（FATE 框架），测试 LR、SecureBoost、NN 等模型，优化模型泛化能力。
- 调研联邦学习在医疗健康领域的应用，输出 4 篇调研报告，分析技术可行性。
- 使用糖尿病、心脏病数据集进行联邦学习实验，验证模型在隐私保护下的性能表现。
- 使用 FATE 框架与 CNN 对早期肺癌进行检测。

2. 非独立同分布（Non-IID）问题研究

- 主要是横向联邦学习中数据非独立同分布的研究，调研基于数据、模型、架构、相似性的方法
- 发表专利 1 篇：横向联邦学习中非独立同分布的方法与装置：利用元学习中的元权重网络来解决横向联邦学习中数据有损坏的标签和类不平衡情况。

2021.07-2022.05 | 货拉拉科技有限公司 | 数据科学组 | 数据挖掘工程师

- 司机等级权益项目（司机画像）：XGBoost 构建订单价值模型，提升履约率 0.3%，降低劣评率 0.01%
- 城市运营问题诊断：设计 41 个指标，熵权法定位城市增长缓慢原因，优化资源投放
- 司机规模测算（时间序列）：使用 ARIMAX，prophet 模型预测司机规模，指导拉新目标制定

2019.11-2021.07 | 平安财产保险股份有限公司 | 车险部 | 数据分析师

- 车险数据化转型：SQL+BI 可视化 搭建日常报表监控体系、商用车报表体系等 6 类 25+张报表，协助成本优化 10%+，节省时间 90%
- 销售人员画像分析：Python+XGBoost 构建销售人员画像模型，提升渠道产能

项目经历

【工业制造】

项目名称：电芯容量预测（天能、赣锋、亿纬） 2024-01 ~ 2024-11 算法工程师

【背景】化成、分容是锂电行业的关键工序，此阶段数据为电池品质的关键体现。解决锂电企业检测电容量过程中能源消耗大、时间耗费长及设备投入多等问题成为迫切需求。

【目标】基于化成、分容数据实现电芯容量超前预测以达到缩短时间、降低生产成本。

【内容】

- ◆ 特征提取：从测试生产实时在线采集的数据中提取容量、静置工步（电压初始值、变化温度、温度均值、工步时长）、恒流恒压充电（恒流：电流均值、电压、温度变化幅度、温度均值、累计时长；恒压：电流变化幅度、温度变化幅度、累计时长）、恒流放电（电流均值、电压、温度变化幅度、温度均值、累积时长等）等 174 个特征。
- ◆ 特征筛选：剔除方差为 0 的特征；保留能提供有效信息的特征，保留所有电芯都具有的特征；最后通过 spearman 系数剔除高度相关特征，最终保留 153 个特征。
- ◆ 模型建立：从具有不同分布的电芯中分别抽取部分样本组成训练集提升模型预测效果，利用 K 折交叉验证评估模型泛化能力

【成果】

1. 预测模型指标 MAPE 与 R2 分别为 0.5%以下与 99%以上；
2. 相较于完整检测工序费时，缩减 20%以上；

项目名称：时代新材虚拟量测项目 2023-06 ~ 2023-10 算法工程师

【背景】“一系簧”产品经硫化工艺后需要进行质检，质检过程平均需要 72~120 小时才能完成，目前需要 100%质检完成后才能出货，整个质检过程严重影响整体生产节拍，成为整个工艺流程的瓶颈。

【目标】根据提供的工艺参数及检验结果数据，构建“刚度”，“压缩高”的数据预测模型，给出模型测算效果，从而减少检测时间和数量。

【内容】

- ◆ 特征工程：对初始数据参数如温度、压力进行均值，取特殊节点数据进行处理，创造新的参数；对已有数据进行去重、空值填充、离群值剔除、因子重要性分析。
- ◆ 建立回归与分类两个模型（XGBoost）：分别建立刚度、压缩高的回归模型；因刚度、压缩高有合格标准，将目标转化为产品是否合格，建立分类模型。

- ◆ 调整分类模型阈值，可以选择合适的漏检率、待测样本占比，作为最终模型运行。
- ◆ 通过回归模型，可挑选出刚度或压缩高异常的样本进行传统的质检。

【成果】

1. 分类模型：实现了分类模型的高准确度，漏检率低于 5%，显著提升了检测流程的效率和准确性；
2. 回归模型：刚度误差 0.02 内占比约 90%+，压缩高误差 1mm 内占比约 92%+。

【研发项目】：企业合规性检查与知识检索系统 2024~05-2024~11 算法工程师

【背景】企业合规管理涉及大量法规、行业标准及公司内部规章，传统人工审核方式成本高、周期长，且难以保持一致性。为提高合规检查效率，减少人工复核成本，企业需要构建一个智能合规性检查系统，使得员工能够通过自然语言查询合规条款，同时支持自动化合规审查。

【目标】

1. 构建企业内部合规知识库，整合政策法规、企业规章制度等文本资源，支持结构化存储与检索。
2. 基于 RAG 技术实现知识召回与问答，使员工能够通过自然语言获取合规要求，无需手动翻阅文档。
3. 开发自动化合规检查能力，支持系统对企业文档进行合规性审查，并给出修改建议，提高审查效率。

【技术方案】

- ◆ **知识库构建**：采集企业规章与法规文件，OCR 解析后进行分块（Chunking）和文本清洗，Embedding 后存 Milvus 向量数据库。
- ◆ **RAG 知识检索与问答**：结合向量检索（采用 BM25 与语义匹配算法）与 LangChain 框架调用开源大模型进行问答生成，实现基于 RAG 框架的高效知识召回与答案生成。
- ◆ **自动合规检查**：通过 API 接口和前端 UI 提供自然语言查询服务，并利用规则引擎与自动化审核模块对企业文档进行实时合规性检查和风险识别。

【预期成果】

1. 提升 60%+ 合规查询效率，员工可直接通过问答系统快速获取相关法规，而无需翻阅大量文档。
2. 减少 40%+ 人工审核成本，自动合规检查系统帮助法务团队快速标注违规内容，降低审核压力。
3. 增强法规管理智能化，企业可实时更新知识库，确保法规检索的准确性与时效性，推动企业数字化转型。

【互联网】

项目名称：司机等级权益 2021-07 ~ 2021-09

【背景】司机服务提升作为平台长期发展核心竞争力，需要一套完善的司机等级和权益体系，来细化司机管理和提升服务水平。

【目标】定义订单价值，判断订单的难易程度；最终改善司机挑单问题，提升履约率。

【内容】

- ◆ 确定分类 label 为是否完成订单，结合业务理解完成相关特征构建与底表搭建，通过 xgboost 建模，筛选重要特征
- ◆ 基于模型的可解释性、可执行性、线上调用效率，最后使用 xgboost 对重要特征进行建模，得到每个订单的分数
- ◆ 进行订单得分分层，选取一定占比的订单作为特殊订单，选定阈值作为特殊订单判断标准
- ◆ 通过 tableau 搭建监控体系，定期监控模型稳定性

【成果】建立订单价值体系；通过司机等级体系的完善，提升月履约完单量 0.3%，降低劣评率 0.01%、客诉率 0.01%

项目名称：司机规模测算 2021-12 ~ 2022.05

【背景】为了创建更好的司机生态，达到业务的稳定增长，需要结合供需关系预测合理的司机规模

【目标】给定订单规模的情况下，确定完单司机规模，推演自然增长的完单司机数，得出每月所需的分车型新增认证司机数

【内容】

- ◆ **预测全年每月拉新司机数**：根据订单目标与单司机比之前的关系确定司机规模，使用时间序列 ARIMAX , prophet 模型预测留存司机数、回流司机数、根据司机数之前的关系，计算出当前供需情况下的所需拉新司机数
- ◆ **预测 m+2 分车型拉新司机数**：结合历史的司机、订单特征与订单目标构建数据集；使用 lasso 预测完单司机数与留存司机数，时间序列 ARIMAX 预测回流司机数，从而计算出分车型所需拉新司机数

【成果】明确供需关系下的各车型司机规模情况；帮助运营侧制定拉新目标，指导 BD 进行业务拓展。