


郑翊民

电话: 19129451156 | 邮箱: yzhengbs@connect.ust.hk | 微信: vinchengme

求职意向: AI垂域应用 算法工程师



教育经历

香港科技大学

2024.09 - 2025.07

计算机科学与工程系和数学系 大数据技术 硕士

- 主修课程: 大语言模型、机器学习、分布式编程、分布式数据处理、大数据算法、自然语言处理

犹他大学 University of Utah

2014.09 - 2019.12

计算学院 计算机科学 本科 绩点: 3.94/4.0

美国犹他州

- 主修课程: 机器学习、数据挖掘、高级算法、计算机系统、计算机图形学、软件开发

实践经历

华为诺亚实验室与香港科技大学

2020.09 - 2023.02

语音语义部 联培博士生

- 主修课程: 深度学习高级主题、深度学习高级架构、机器学习、数据挖掘、组合优化、计算机视觉
- 在校期间完成博士课程并参与郭天佑教授实验室项目, 获得**华为博士奖学金**(2020-2022, 高于常规博士生25%津贴)。
- 华为实习期间, 担任AI实习工程师, 推动语言模型高效微调与黑盒优化结合。调研了前沿参数高效微调算法, 验证了 Prompt Tuning等向量提示词微调在垂直领域任务的参数效率优势, 探索了针对语言模型的**向量提示词黑盒搜索**方法。
- 博士生联培期间, 我深入了解到基础理论研究与行业实践的差异。综合疫情对个人规划的影响, 意识到将科研成果转化为应用是我更偏好的职业选择。因此, 我选择从博士生转为香港科技大学硕士, 以更专注于实用性。

香港科技大学

2021.02 - 2022.06

计算机科学与工程 教学助理

- 提供 机器学习、数据挖掘、金融数据挖掘 等本科及研究生的实验课, **累计全英授课15节**, 共10小时。

专业技能

- 程序语言: Python (熟悉) / MATLAB (掌握) / C++ (掌握)
- 理论研究: 深度学习 / 语言模型微调 / 多目标优化
- 操作系统: 基于 云平台 / Linux / WSL 进行远程协同开发
- 其他技能: PyTorch / 数据结构与算法 / 分布式计算 / 开源开发

项目经历

文本增强混合线性专家的时序预测模型

2024.06 - 2025.02

香港科技大学

- 该论文提出并实现了**语言模型增强的混合线性专家模型**, 引入双模态信息融合机制, 解决传统模型信息利用不充分的问题。同时, 通过设计多尺度线性专家模块, 显著提升了模型在长时间序列预测任务中的准确率, MSE 降低 15%。
- 在项目代码实现阶段, 参与语言模型整合与代码逻辑重构, 统一测试标准, 实现模型公平比较。完成专家数量影响、组件分析、效率等实验的代码和论文, 经多次实验验证模型有效性, 为项目提供可靠数据支持。

改进检索增强生成 (RAG) 问答系统

2024.10 - 2024.12

- 该项目改进了 RAG 问答系统的生成过程, 利用 **Llama-2** 和提示模板进行检索文档的二次过滤, 以提升回答准确率, 从基线 0.287 提高至 0.354。并实验验证了系统在处理目标文档位置和干扰文档数量变化等多样化检索场景下的鲁棒性。
- 实现 RAG 生成的二次筛选, 设计 Llama-2 提示模板和评分机制, 剔除干扰文档, 提升检索质量。

基于最大值熵搜索的并行多目标贝叶斯优化

2021.03 - 2022.05

香港科技大学 郭天佑教授 (James Kwok) 实验室

- 该项目提出用于**多目标黑盒优化**的并行最大熵搜索方法, 利用高斯过程实现黑盒的并行评估, 通过最大化批量评估点整体在输出空间帕累托前沿的信息增益来优化, 实现高质量平行测试黑盒能力。适用于**方案设计和资源分配的决策优化**。
- 在郭天佑教授指导下深度参与项目, 承担核心算法研发工作。在优化函数的推导过程中, 投入大量精力攻坚克难, 独立完成了截断多元正态分布的统计学特性等**数学推导**工作, 为算法的准确构建和高效运行奠定了坚实基础。项目推进过程中, 我深入钻研并行多目标、贝叶斯等优化理论, 系统学习高斯过程、超参数优化等工具的应用, 有力推动项目进展。

Probabilistic Streaming Tensor Decomposition (ICDM'2018)

2017.11 - 2018.08

犹他大学 折闪电教授 (Shandian Zhe) 实验室

- 该**ICDM'2018论文**提出一种基于 CP 分解的流式概率张量分解算法, 可处理任意顺序的输入数据, 实现在线嵌入更新和预测, 并提供确定性量化, 支持各张量模式的动态增长。相较传统方法在动态数据场景下表现出更强的灵活性和预测性能。
- 成功通过**矢量化编程**将论文算法的 MATLAB 代码执行效率提高 25 倍, 为团队节省了 400 小时计算时间。