

张先生 大模型算法

北京 | 7 年工作经验 | 硕士 | 1991.10 | 男 | 中国民航大学 | AI 算法 | 2017 | 硕士
13516231336 | klzhang1002@163.com | <https://github.com/zkailinzhang>

教育经历

中国民航大学	硕士	信息与通信工程	2014.09-2017.05
天津职业技术师范大学	学士	通信工程	2010.09-2014.07

技能清单

编程:Python/C++/Linux, 熟练 huggingface/pytorch/tensorflow/opencv, docker/flask/ncnn/mysql
算法:tf-idf,lstm,FastText,BERT,gpt2,Llama,Qwen,Clip,stablediffusion,GRPO,DAPO,RoPE,Lora,kvCache,Faiss,
推荐双塔模型 dssm/youtube,精排 DIN,DSIN 以及 CV:maskRCNN,FaceNet,Yolov5/v8,DETR,DeepSort,ReID

工作经历

- 北京中科某科技有限公司 算法研发

2024.04 - 至今

研究最新文献和 Qwen,DeepSeek,Llama 源码和落地, 训练和搭建工业基座模型和多模态大模型以及 RAG 和 Agent 搭建, 处理垂域业务数据和清洗文本和图像数据, 结合书生·万卷通用知识和工业知识库, 进行基座模型从零预训练, 在多台 8*A100 上基于 deepspeed,megatron-lm 框架 4D 并行从零预训练,全量训练,Lora 微调,DPO,RAG,rlhf 及多模态 LLaVA/InternVL/QwenVL 等模型研究, 基于 DeepSeek-R1 蒸馏小模型训练, 研究 MoE,Qwen-MoE, 以及强化学习 PPO,DPO,GRPO 等, 以及推理 vllm/llama.cpp/tensorrt-llm 部署优化等
- 天津天瞳威视科技有限公司 算法研发

2021.11 - 2024.03

1. 研究自动驾驶感知预测规控等模块, 优化自动驾驶感知算法和模型, 研究 StableDiffusion 生成自驾领域场景数据, 研究多模态大模型 QwenVL 自驾突发事件预测, 以及 TensorRT 和 TensorRT-LLM 量化推理部署
2. 联合采埃孚打造多家汽车主机厂的泊车智驾量产和无人巴士, 基于深度学习车道线,库位,跟踪,ORB-SLAM, HyridA*,训练模型 UniAD/ViT/yoloX/RepVGG/ByteTracker/PINet/Nerf,以及 BEVFormer、3D 语义占用网格预测 TPVFormer, 多家自动驾驶芯片地平线 J5/J3,华为 MDC610/黑芝麻 A1000 等模型转换和推理优化
- 央视未来电视有限公司 算法研发

2019.10- 2021.11

1. 主要 OTT 智能家庭终端场景,包括智能视频分析和视频个性化推荐,在广告推荐,作业个性化推荐,课程续报转化等方面的结合深度学习 BERT 的研究开发和提升, query 意图, 双塔模型, 多路召回, 粗排精排模型, 向量模型检索 faiss+GPT-2 实现智能客服会话,fasttext 和文本相似,作文生成技术探索落地, 提高点击率和在线时长。
2. tensorflow/faiss/milvus/tornado/hadoop/flink/docker/hbase/tfserving, 搭建视频大数据实时个性化推荐平台, 主导推荐算法的其他渠道和公网的适配开发, 协助视频大数据物料库的标签标注工作, 数据魔方的机器学习模型分析开发, 智能搜索的立项和模型开发, 已发表算法相关专利 5 篇
- 北京联想新视界科技有限公司 算法研发

2017.05 - 2019.10

1.基于 OpenCV/TensorFlow/PyTorch/Docker/tf-serving/K8S/kubeflow 库, 对联想合肥联宝工厂整机自动生成线车间智能改造、以及华能集团, 浙江苍南风电,西安热工院,陕鼓等火电风电集团进行 AI 赋能
2.基于 maskrcnn/Yolov5/v8,paddleocr 等完成 AR 巡检, 仪表识别自动读数, 现场设备跑冒滴漏, 输煤小车泄露, 动火点检测等, 以及移动端模型框架 PaddleLite、NCNN 迁移量化部署, 树莓派侧部署等, 以及门禁人脸打卡,工服佩戴识别,以及基于 Kinect 和 AR 眼睛的 3D 物体检测定位,OCR 等, 基于注意力机制的工业时序预

测模型 AttnConvLSTM,进行电厂智慧监盘,多目标优化车间智慧调度,全设备生命周期模型预测等; 完成深度学习训练平台 Tengine 和服务部署框架的搭建工作,撰写相关算法专利 2 篇;

项目经历

搭建从零预训练和微调的垂直领域工业 7B 通专一体大语言模型

项目描述:

针对工业钢铁行业的各工艺车间监管控, 点巡检, 设备运维决策, 知识库故障库等搭建基座 LLM, 具体包括炼钢车间冷轧车间等, 空压站房循环水系统站房等工艺手册, 设备说明书, 历史巡检记录和故障维修工单以及解决方案, 覆盖产品辅助设计,质量检测,设备预测性维护等场景, 探索大小模型融合增量训练方案的落地,并通过三阶段训练框架实现行业知识深度融合, 最终在实际应用中显著提升工业问答准确率与设备维护效率。

职责贡献:

基于天工数据集和书生万卷数据集以及整理的私有工业数据集进行模型的从零预训练, 具体基于各种文档以及故障-原因-设备-需求-方案 neo4J 图谱数据库, 结构化数据库测点报警记录, 以及视频片段和振动图谱等多源异构数据共约 90G 数据, 使用 flashtext/pdfplumber/datasketch/nougat/nltk 库处理整理 jsonl 格式,公式 markdown, 网络参考 Qwen2-7B, 关键词提取扩充原词表, 首先基座模型预训练通用知识 WanJuan1.0, SkyPile 和部分行业数据, 第二阶段筛选高质量行业 SFT 指令微调训练, 最后 DPO 偏好对齐阶段,基于 Megatron-LM 进行 4D 并行策略训练,DeepSpeed Zero-2, 8*A100 (40G) 配置, 进行全量预训练, bf16 混合精度训练, 启用 flash-attn 和 vllm, 训练不同实验配置, 先小样本 9k 条数据验证全流程调参, loss 震荡检查梯度范数降低 lr, 保证显存利用率 85%以上, 轮次 5 轮, 训练 12 天 loss 稳定在 0.14, 推理优化量化分页批次请求,TTFT 控制在 50ms, 问答准确率从 baseline 65%提升至 89%。

搭建基于 Deepseek-R1 蒸馏 Qwen-32B 模型具备推理能力的设备故障助手微调训练

trl/verl+transformers+unsloth+lora+sft+fastapi+vllm, 搭建数据集, 设备故障 cot 数据集基于 deepseek-r1 问答提取思考内容 3k 条, 经过人工修正以及和业务专家标注的 1k 条, 进行 SFT 训练, 仅对注意力头的投影层应用 lora, 秩 8, 总批次 16, 启用梯度检查点, 2 轮, loss 从 2.4 下降到 0.5, 故障代码召回率@5 ≥ 0.82 , 解决方案可执行率 $\geq 90\%$, 前端页面以及 API 接口其他系统, 故障解决方案效果达到要求

搭建基于 GRPO 和 DAPO 强化学习训练的具有思考能力的 Qwen3-8B 工业知识模型

研究 GRPO 和 DAPO 公式对比, 定义系统提示词, 设置温度系数 0.7, 启用采样生成, 轮次 1, bf16 和 vllm 优化, 最大化标准化组优势+最小化当前策略和前一策略模型概率的 KL 散度, 每个 Prompt 采样 16 次, 梯度累计 4 步, 奖励函数定义为格式模糊匹配和完全匹配, 正确性和结果数字奖励, 正则匹配格式完整性等, 微调训练参数 1.6%, 训练 loss0.01

搭建工业大模型稀疏 MOE 网络进行 SFT 微调训练

研究 llm-moe 代码包括 llama, ds 和 qwen,模块包括 RMSNorm kvcache,rope,swiglu,router,expert, 路由器线性层, 路由策略归一化路由得分, 生成路由策略专家索引, 组合权重, 分派掩码,auxiliary loss 专家负载均衡, 将专家处理的 token 数量与其被路由到的概率相乘求和, 尝试多种实验配置 Top-2/4, 偶数层 mlp 奇数层 expert, 训练步数 8k 步, loss 从 6.7 降到 1.3

基于 siglip+qwen2.5 工业多模态图文大模型预训练和搭建

项目描述:

聚焦工业场景中设备故障识别、维修决策支持及设备知识交互等核心需求。通过整合工业领域语料与多模态数据, 经预训练和 SFT 微调, 实现对工业图文信息的精准理解与生成, 为现场运维、设备管理提供智能辅助, 在工业现场实现一张图一整套维修决策的少样本泛化能力。

职责贡献:

Qwen2.5-7B-Instruct 和 siglip-so400m-patch14-384, 从工业行业整理文本语料中包括设备故障维修决策描述等, 以及开源多模态通用图文对数据集 WanJuan 140G, 工业故障和正常图文对 1:9, 18 类故障, 现场人员改写优化维修决策文本, 进行两阶段的训练, 预训练把 vit 参数冻结仅训练文本模型, 输入提示包括 提示 +images pad, 图像特征占位符 49 个, 1 epoch 完成视觉-语言对齐, SFT 基于指令微调数据故障诊断、设备介绍、维修指导三类任务继续训练 3 epoch, 采用 cosine 退火 + 梯度 checkpointing, 4 卡 A100 40 GB 18 h 完成。在测试数据集中够达到 96%@top3 的识别准确率, F1-score 达 94.8%, 已在 3 条产线试点, 现场工程师反馈减少 35% 人工查阅手册时间。

搭建基于 Qwen2.5-VL 和 Intern2.5-VL 的工业多模态大模型 SFT 微调训练

数据包括工业设备故障图像库包括轴承磨损、管道泄漏、电机异响对应的视觉特征、故障文本描述含维修手册片段、故障代码解释、现场运维记录通过 SFT 微调, 基于设备图像直接输出故障类型、成因分析及维修建议, 系统最终在工业测试集覆盖 10 类典型设备、18 故障类型上实现故障识别准确率 94.3%, 较通用模型提升 28%, 为工业运维团队提供即拍即诊的智能辅助工具, 缩短故障排查时间 25% 以上, 降低人工误判率。

搭建工业行业垂域知识检索增强 RAG 系统

项目描述:

构建了一套面向工业制造, 覆盖设备运维、故障诊断、操作指引, 参数查询、安全合规检查等工业典型场景的 RAG 智能问答框架, 融合文档理解、语义检索、图谱召回、多跳推理, 可溯源等, 融入安全合规校验与引用溯源机制, 满足工业场景对操作规范性、结果可追溯性的严格要求, 实现文档知识→智能问答→决策辅助的闭环

职责贡献:

BERT/BGE/Qwen+LlamaIndex/LangChain+Faiss/Milvus+Neo4j+fastapi+docker+unicorn+gradio, 收集工业文档预处理 pipeline 设计, 采用 hanlp 分句 + RSE 语义聚类 + CCH 上下文补充策略, 提升 Chunk 语义完整性, 使用 9k 条故障案例与操作手册进行领域微调 embedding 和 rerank 模型, 同时构建 query 意图定义分类 bert 模型训练, 对 query 意图识别分类, 实体抽取对 query 改写优化, 基于提示相似度计算语义召回和 BM 文本召回, 以及图谱多路召回, 然后进行 RRF 融合和 MMR 去重多样性, 最后喂入 Cross-Encoder 重排模型, llm 温度系数 0.5 以及添加人工后处理检验, 输出问题定位和对应解决方案, 避免自由发散和幻觉减少 63%, 关键信息准确率较 baseline 提高 87%, 问答准确率达 91.3%, 平均响应时间 <3.8s, 显著提升一线工程师问题解决效率, 降低误操作风险。

搭建工业行业车间智慧调度和智慧排产助手 ReAct Agent 系统

项目描述:

为解决传统制造车间排产过程中目标单一、能耗高、约束复杂、响应滞后等问题, 本项目构建了一套融合运筹优化与大语言模型的智能排产系统, 基于 LangGraph 实现状态机驱动的多智能体协作架构, 在满足严格工艺与资源等式和不等式约束的前提下, Pareto 前沿求解同步优化生产效率、能耗最小化等多目标, 支持动态重调度与可解释报告输出, 具备高工业落地价值。

职责贡献:

Qwen+AutoGen/LangGraph+OR-Tools/Gurobi+fastapi+docker+unicorn+gradio, 开发 workflow 多 Agent 协作包括订单解析、约束建模、能耗评估、MIP 求解、执行监控, 定义节点包括订单、工序、设备、班次、能耗表; 定义边为工艺先后、设备可用性、能耗转移, 状态机为当前排产快照, 通过记忆模块存储历史约束满足案例与优化策略, 结合反思机制持续迭代目标权重与约束参数, 实现在满足所有等式与不等式约束的前提下, 较传统排产降低能耗 21.3%, 最佳开机组合的能效比提升 18%, 订单准时交付率保持 99% 以上, 为高约束、高耗能工业车间提供精准化排产解决方案。

搭建基于 YOLOv8 和 CLIP 的视频智能风险分析 Agent

基于 transformers 的 agents 模块 ReactCodeAgent 搭建视频分析 tool 和报告分析 tool，定义提示词，每 2 步重新规划，具体对工厂重点现场监控视频进行抽帧，yolov8l 检测定义的危险规则库包括人员跌倒，未佩戴安全装备等异常行为或动物侵入，检测画面和预设描述文本和安全文本喂入 clip 输出风险评估概率，检测视频帧或视频中的异常，给出处理建议。

基于 Qwen-VL 的 BEV 俯视图理解车辆周边异常行为事件预测的多模态模型

项目描述：

将车载环视 6 路相机图像拼接生成鸟瞰图 BEV，喂入 qwen-vl 多模态大模型，实现对行人横穿、非机动车逼近、车辆加塞、倒车干扰等异常事件行为的端到端识别感知→语义理解→事件推理→预警生成，实现毫秒级长尾事件预警，趋势与潜在风险，并输出结构化事件标签与自然语言描述，输出结果对接 ADAS 决策模块与车内 HMI，支持语音播报与视觉提示。

职责贡献：

transformer+peft+qwenvl utils+tensorrt-llm+orin，首先构建 BEV 俯视图的异常行为图文数据集，定义文本描述车辆周边是否异常、风险等级、预警文本，涵盖 10 类高频风险事件，对 6 路相机环视畸变矫正拼接 bev，构建 1.2w 图文对，基于 qwen-vl 进行 LoRA 高效参数微调，最终模型在测试集上实现 90.1% 的事件识别准确率，输出与文本标签的 BLEU-4 达到 0.78，基于 TensorRT-LLM 对模型量化采用 int4_awq，编译生成 engine，在 Orin-X 处理 BEV 输入延迟量化推理在 200ms 以内，完成输出事件类型、运动趋势和潜在风险

基于 LLaVA 进行 SFT 微调搭建多模态大模型

基于开源数据集 CC3M，60w 条图文对进行预训练和微调，llava-v1.5-7b，clip-vit-large-patch14-336，deepspeed，zero2 no offload 进行模型 LoRA 微调，启用 flash-atte，训练轮次 100，loss 从 4.2 降到 0.002，分别对视觉层，转接层，语言层，进行冻结 部分训练，全量训练实验，lora 微调效果最好

基于 Stable Diffusion 的个性化自动驾驶场景图像生成系统微调与部署

基于 stable-diffusion-v1-4+CLIP+LoRA+FastAPI+Diffusers+gradio，收集并清洗了 100 张高分辨自动驾驶场景图像及文本描述同时进行裁剪、旋转等增强操作，以及字典里添加新词，冻结 vae 和 clip，嵌入层和 unet 进行 lora 训练，TensorRT 加速至 210ms，开发了交互式界面输入自定义文本选择预设模板来引导图像生成。

新能源势力多款车型行泊一体智驾算法系统搭建

基于地平线双 J5 和英飞凌 TC397，以及双 TDA4 低阶版，功能包括全景影像 SVM，道路动态标定，相机位姿在线估计，APA，指尖泊车，记忆泊车，城市和高速道路智驾，车道线检测和拟合，动态车辆和行人检测，静态障碍物检测和测距，轨迹预测和分析，路径规划混合 A 星等实际落地量产功能。环境 8*4090，2*A100，训练模型基于有 Yolo+RepVGG 重参数化，map@0.5 和 @.5:95 指标上在周视前视定义的 13 个环境目标平均提升一个点；基于 PointPillars,Sencond,泊松重建对激光雷达点云搭建真值系统，基于 PiNet 车道线检测和跟踪，Yolo+ReID 多相机目标融合，雷达和相机联合标定，亲自搭建 3D 雷达真值采集车以及 4D 标注，另外进行 TPVFormer 模型和 OpenOCC 模型训练和 J5 模型部署上车调试运行等等

基于深度学习的个性化视频实时推荐系统

项目描述：

央视某公网产品日活 3 百万，视频物料 CMS 库近百万节目，主要包括长视频节目，电影电视剧综艺儿童等题材，以及一些新闻资讯类节目。推荐场景包括猜你喜欢，相关推荐，热搜热播。基于深度学习，对用户做人物偏

好画像，对节目抽取特征做视频画像，解决大数据下的视频个性化推荐和长尾推荐，减轻运营成本和提升用户活跃和粘性，提升点击率和转化率。

职责贡献：

youtubednn+deepctr+hadoop+spark+flink+xdeepfm/din/dien/dsin+faiss+Vott,利用物体检测和人物识别做视频基础标签工作，结合 APP 日志做视频画像和衍生特征，推荐包括召回和排序，由于家庭是多人场景，创造性提出基于图像领域的胶囊网路 CapsuleNet 做多嵌入向量召回，完成家庭多人画像表征，排序模型引入注意力模型，多头注意力去学习当前电视面前的用户偏好，线上 ABtest 较协同和人工对比，CTR 频道均提升 100%，人均观看时长提升 60%，目前已上线，全部替代运营同学，同时输出专利 4 篇。

教师端 APP 学生作业个性化推荐

项目描述：

针对老师 APP 作业智能练习入口,通过埋点数据利用深度学习模型分析构建班级学情画像和老师画像,为不同的班级学习情况因材施教个性化推荐,更好的用户分层,增加学生粘性和续报率。

职责贡献：

主要负责模型结构和特征处理方面,利用 app 埋点日志及 mysql 历史数据多表抽取构造老师/题目/班级的细粒度特征,及上下文特征和历史作业特征,指标推荐列表的 topN,基于 self-attention 不断去尝试改进模型结构,fasttext 对题目简单分类,位置编码,多头个数,嵌入维度,特征交叉,数据增强等 trick,最终的 top5 88.1%,top10 98.9%(baseline DeepFM:top5 62.5%,top10 79.2%),部署 tf-serving 模型日更在线学习。

基于 GPT-2 搭建 AI 智能客服

项目描述：

针对网校辅导老师和运营人员与用户的微信群聊天语料,搭建基于 AI 的智能对话,包括检索式和生成式,场景涵盖智能客服类的轻服务,话术推荐动作推荐的重服务类型,减少 ROI,更好的引导相关人员对用户的专业快速准确响应及学生转化率。

职责贡献：

对 10wQA 语料进行处理,检索式直接根据 word2vec+tfidf 计算问句相似性,生成则尝试了 seq2seq+attn,GPT2 主流模型,训练解码端采用 greedy+teacher,测试也尝试了不用 trick:beamsearch,top-p sample 及各种参数,通过业务人员验证,较好的话术环比提升续费率 40%。

课程广告 CTR 预估和实时在线推荐

项目描述：

针对家长和学生 APP 端中各个 banner 滚动及落地各个广告渠道,搭建基于 Hbase 和 Flink 在线实时深度学习模型 CTR 计算,线上实时特征计算和召回,线下模型训练,提流量使用效率和管理广告投放,提升复课率扩课率。

职责贡献：

主要负责 CTR 深度学习模型搭建和改进,引入注意力机制,在 DIEN 模型基础上针对教育业务场景改进,不断优化完善广告画像,学生家长画像,深度挖掘特征,同时添加广告图像 CNN 模块分支,多模态特征,对比实验在历史点击序列上自注意力模块 2 个 heads/2 个 block,指标 AUC0.995 和 F0.1 0.6 达到最优。

多模态多任务短视频 feed 推荐：

由于短视频标签的匮乏和不准确性，提出基于深度学习多模态的短视频推荐，包括语音，文本，图像特征，基于 mfcc+lstnet 提取语音特征，背景和语音，文本包括 title，ocr 等，图像特征封面和 up 主头像，背景风格等；衍生特征包括 up 主日更周更，粉丝流失率，用户一二级分类偏好，节目点赞统计，快速滑动率统计等，另外爬虫全网热点舆情，实时语义匹配推荐；深度学习模型采用多任务框架，一个 base 模型两个分支预测点击概率和观看时长预测，数据集 60 万 items，线上 ABtest，CTR 各频道平均提升 200%。输出专利 1 篇。

智能视频搜索引擎一体化平台

项目描述:

公司生产资料是视频,包括自营和三方合作视频,搭建智能搜索,一方面可以在公司各个业务线上发挥巨大作用,另外在产品上也可以输出,搜索时联想和搜索结果推荐;原有基于 elasticsearch 是关键词匹配,基于 AI 的智能搜索,是语义匹配,更精准的找到目标视频和长尾视频;主要模块 Item 内容理解、Query 理解、检索召回、排序模块,结果每个视频用深度学习嵌入向量 128 维表征,存储到 Muilvus 嵌入向量索引库,进行 ANN 查询。

上海石洞口电厂智能设备辅助巡检平台

项目描述:

智能设备辅助巡检平台是在传统技术的基础上,叠加物联网、大数据、人工智能、AR 技术、图像识别技术等,AR 增强现实技术在燃料系统内的深度运用,解决燃料系统中针对设备存在的人工巡检劳动强度大,作业环境恶劣,巡检频率高,巡检规范难控制,存在不及时、不到位、不准确等诸多问题,提高生产组织的安全、快速、全面和准确性,进一步提高燃料系统生产运行和管理效率。

职责贡献:

框架 flask+gunicorn+supervisor+nginx+tf serving+docker+ncnn,负责搭建算法库,包括卸煤小车定位,动火点监测,煤仓外溢,输煤管堵塞,输煤皮带跑偏撕裂,煤仓煤位识别,基于 YOLOv8,DeepSort 模型,pix2pix 模型,EKF, Hough 变换,以及各种算法设计,实现在现场复杂环境实现算法功能满足客户需求。

搭建 IEngine 机器学习和深度学习训练部署一体化云平台

项目描述:

基于开源框架 KubeFlow 搭建深度学习模型平台,包括数据准备,数据处理,模型训练,预测服务,服务管理等模块,cifar10 多机多卡分布式训练;基于 TipDM 搭建机器学习平台实现模型插件拖拉拽等可视化操作,数据上传操作,模型训练和评估和在线部署等。从深度学习任务数据标注,分布式训练,模型部署上线,到全栈式平台管理版块,通过集成平台 API 接口投入实际业务应用.底层基于 K8S 和 istio 等技术,以及 KubeFlow,支持 Tensorflow, Pytorch 常见框架,jupyter notebook,tensorboard 及日志监控看板。

建筑现场智慧大脑

项目描述:

1.依托 AI 和大数据搭建工人现场作业下的智能监控和预警系统,项目内容包括:门禁人脸识别,身份证 OCR 识别;现场工人是否佩戴安全帽的识别;工人工作轨迹记录和再识别;禁区出入检测电子围栏;无烟作业的环境下工人抽烟和明火检测;在建楼高预测。实时数据流计算分析,更好的跟进施工建筑项目进度和安全保障。

职责贡献:

主导负责,针对施工现场复杂环境以及人员不同的位姿,佩戴安全帽和未佩戴安全帽,利用 lableme 打标签,基于易训练且准确率高的 MaskRCNN 模型训练,在测试集上 mAP 95.8% .2. 工人的不同场景下的再识别,基于带有注意力机制的 PCB-RPP 模型,在首先是硬区分,然后带权重的软区分,分层学习率,在两块 GTX1080Ti 上训练 10 个小时,准召都在 96.50%以上。

致谢

感谢您花时间阅读我的简历,期待能有机会和您共事!