

个人简历

姓名 赵天一 性别 男 出生年月 1997.3 籍贯 浙江海宁
邮箱 307587809@qq.com 电话 (+86)15026421912



教育背景

纽约大学, 硕士, 坦登工程学院 Tandon School of Engineering

2021 年 5 月获得计算机科学 Computer Science 工科硕士学位。

上海交通大学, 本科, 上海交大-密西根大学联合学院 UM-SJTU Joint Institute

2019 年 8 月获得电子计算机工程 Electrical and Computer Engineering 工科学士学位。

工作经历

上海燧原科技有限公司, 软件工程师 2022 年 12 月 – 至今

燧原 2 代、3 代、4 代 AI 芯片软件栈开发, 涉及算子开发调优、框架开发、分布式部署等。支持天津智算、中移动、腾讯、美图、B 站等客户 AI 应用落地。业务包括:

大模型推理: 大模型在一体机、推理集群上的分布式推理部署; 自有大模型推理部署框架研发;

大模型训练: 自有训练框架研发、第三方训练框架适配、TransformerEngine 等 GPU 加速库迁移;

传统模型推理: 各级缓存算子融合优化; 燧原 GCU 算子功能开发与性能优化; 图优化 pass 开发; 模型业务层面性能瓶颈分析等。

华为技术有限公司-海思图灵解决方案开发部, 算法工程师 2021 年 8 月 – 2022 年 11 月

昇腾 AI 芯片编译软件栈算法开发, 包括图优化算法、算子性能优化、芯片带宽优化算法等。

项目经历

大模型分布式推理部署, 燧原科技 2025 年 2 月 – 至今

- 基于燧原 3 代、4 代 AI 芯片, 落地 DeepSeek V3 等热点大模型分布式推理方案。分别根据一体机和推理集群特性, 定制分布式以及模型部署策略。
- 设计并使能 CUDA Graph、MoE 定制化通信、通信计算并行等性能优化手段。
- 开发适配 sglang、vllm 等主流推理框架; 根据燧原 GCU 特性, 优化算法层代码; 设计算子极致融合方案, 在 4 代芯片上实现部分算子, 并接入框架。
- 基于 Dynamo、Mooncake 等思想, 实现 PD 分离、智能路由、分布式 kvcache 管理等推理集群优化特性。

大模型训练框架研发, 燧原科技 2024 年 9 月 – 至今

- 根据 Megatron、DeepSpeed 等主流框架使用痛点, 研发燧原自有大模型训练框架, 支持 5D 分布式并行训练、通信计算隐藏、FP8 训练、零冗余显存优化等特性, 并适配燧原 4 代训练芯片, 达到高性能集群训练目标。

2. 迁移并适配 TransformerEngine, FlashAttention 等 GPU 底层加速库, 开发燧原 4 代 GCU 高性能算子。

传统模型算子自动融合与图优化, 燧原科技 2023 年 3 月 – 2024 年 10 月

- 1. 在燧原 2 代、3 代推理芯片, 开发分别基于静态、动态图计算的 L2 级缓存算子融合引擎 (Auto Fusion Engine / Dynamic Auto Fusion Engine), 并在此基础上持续开发常数预取 (constant prefetch)、自动图切分 (auto tensor split)、DMA 搬运融合等相关优化特性, 达成泛化的传统模型性能提升。
- 2. 开发燧原 GCU 硬件强相关的图优化 pass, 如 weight 重排 pass 以提升 DMA 效率、tensor dtype 自动转换 pass 等。

推理性能瓶颈分析及业务优化落地, 燧原科技 2024 年 2 - 7 月

- 1. 在燧原 3 代推理芯片, 对多种业务模型进行端到端的性能瓶颈分析, 对模型和算子理论 cost 分析优化点, 由上至下包含: 算法等价性优化, host cpu 逻辑优化, H2D、D2H 通信与计算隐藏, 显存占用优化, runtime 算子下发, 各级缓存算子融合, DMA 搬运效率, 算子 kernel 计算效率, cache miss 优化等。建模理论性能目标并制定相应优化方案。
- 2. 开发并优化业务需求重点算子, 主要是 2D 类 (matmul, conv 等)、softmax、attention 等。支持多种形态 AI 应用落地, 如 SD 文生图、Dit 文生视频、搜广推、CV 目标检测识别、OCR 文本总结等。

自有大模型推理框架研发, 燧原科技 2023 年 8 月 – 2024 年 3 月

研发适配燧原 GCU 的轻量级大模型推理部署框架, 支持 Llama2、Baichuan、ChatGLM2、HunyuanDit、BloomZ 等多种开源大模型。配合算子团队分析并优化大模推理性能, 达成互联网业务落地。

动态 shape 自动融合发现和融合算子优化, 华为海思 2022 年 1 - 10 月

为解决图融合模板泛化性和动态 shape 算子性能问题, 开发动态 shape 算子自动融合整体方案并在昇腾平台验证。基于图级细粒度算子切分信息和算子 DSL 制定融合划分策略; 采用 PolyHedral 多面体技术进行融合算子 IR 循环优化和调度优化, 搜索最优 tile 策略; 适配后端 IR 优化 pass。自动生成融合算子 kernel 从而优化动态模型性能。

算子粒度芯片 QoS 带宽自动调优, 华为海思 2022 年 2 - 5 月

针对 QoS 芯片带宽分配瓶颈问题, 分别开发硬件模块粒度和算子粒度的调优方案。应用支配树等图算法减小搜索空间, 移植并应用 TPE 等贝叶斯优化算法进行黑盒调优, 在真实模型业务上验证。

基于 Taso 的数学等价子图变换项目, 华为海思 2021 年 8 - 12 月

基于 Taso 论文思想开发模型子图等价变换生成, Z3 求解器验证等功能。通过子图匹配替换搜索, 达成减少图级数学计算量、使能高效指令、图融合模板泛化等优化目标。

能力与兴趣

编程语言: Python, C++
工具应用: CUDA, MLIR, TVM, Tensorflow, Pytorch
职业方向: 软件开发, AI Infra, AI 编译器等