

周晨扬

年 龄：26岁

籍 贯：浙江嘉兴

政治面貌：中共党员

联系电话：18868024184

联系邮箱：1178574011@qq.com

个人网站：carpediemyang.cn



教育背景

2021-09 ~ 2024-06

上海大学

计算机科学与技术 (硕士)

专业成绩：88.33/100 (专业前5%)

研究方向：推荐系统、**群组推荐**、图神经网络、深度学习研究成果：Dual-View Fusion and Dual-Graph Convolutional Network for Group Recommendation (**PAKDD**录取)

2017-09 ~ 2021-06

中国计量大学

计算机科学与技术 (本科)

专业成绩：3.55/5 (专业前5%)

毕业设计：基于局部特征的行人再识别

主修课程：Java面向对象编程、组成原理、算法与数据结构、数据库技术、计算机网络、操作系统

工作经验

2023-09 ~ 2024-09

Decoda.ai (Google 初创团队)

大模型算法工程师

技术栈：next.js、tailwind css、react、python、chromadb、fastapi、postgresql、github、docker**主要产品 (出海业务)：**详情：carpediemyang.cn/experience/work/decoda

负责从**0到1**的构建产品，核心参与了产品的开发生命周期，从需求分析、系统设计、实际开发和部署以及部分运营，具有宝贵的产品经验；搭建推动团队 CI/CD 的建设，熟悉技术工作流程，负责协调各项开发工作安排。

Your Fantasy AI： 基于LLM交互式剧本、角色扮演、情感陪伴等**情绪价值服务**；

- **担任角色**：算法工程师；**开发周期**：2023.10—2024.2；**代码量**：95commits, 20000+改动
- **负责功能**：1. **prompt engineer**，设计结构化prompt flow；2. 图文**RAG增强**服务，构建跨模态检索增强生成系统；3. 动态交互剧本生成，基于llm交互故事生成框架 4. 角色属性实时演算系统，根据用户和对话，实时捕捉角色属性。4. 角色扮演**大模型微调**：结合设计基于Lora的微调方案。

Dreamle.AI： 产品重点是提供多模态的情感陪伴服务，支持角色朋友圈、排行榜和长期记忆等情感陪伴。

- **担任角色**：**全栈**工程师；**开发周期**：2024.4—2024.6；**代码量**：前后端20000+
- **负责功能**：1. **聊天功能** (核心)：设计聊天相关后端所有功能；2. 首页推荐角色**推荐排序**，匹配用户喜好；3. 长期记忆**RAG**服务：独立设计角色记忆增强系统；4. 多模态内容交互，图片发送和解锁。5. **语音模型**：**负责TTS**功能，语音模型的集成，**提供语音交互**。

2024-10 ~ 至今

MagikCompute.ai(魔形智能)

大模型推理优化工程师

1. 大模型推理优化与部署工作，优化**DeepSeek-R1**性能，支持专家并行策略，吞吐量提升30%；设计自动性能测试的workflow。
2. 基于**K8s**多集群搭建弹性推理引擎，集成**LWS**的动态扩缩容，根据实时业务量，实现自动扩缩容。
3. 构建**Prometheus+Grafana**监控体系，管理GPU集群，实现服务的告警机制和自愈能力。
4. 基于**fastapi**框架算力平台后端实现功能，主要负责登陆注册、用量统计、模型部署功能；产品页面设计，基于figma的原型设计

核心能力：大模型推理优化 (PyTorch/Vllm) | 云原生 (K8s/LWS/Helm) | 监控 (Grafana/Prometheus) 后端开发：

FastAPI/PostgreSQL 工程协作：Figma/Docker/CI-CD

专业技能

- 熟悉Pytorch框架，熟悉图和超图的数据结构进行**群组和用户推荐**；了解**对比学习**相关知识和研究进展；

- 了解Transformer结构和LLM相关，了解大模型推理加速和算子融合；参与LLM相关产品应用搭建；
- 熟悉大模型RAG和知识库服务，熟悉相关向量数据库，结合chromadb设计和存储服务；针对不同大模型有丰富Prompt内容和参数微调经验，
- 熟悉Python基础和数据类型，使用Fastapi框架搭建后端，搭建模型，调试和优化模型；
- 熟悉Linux下的编程环境和终端指令，掌握docker指令，熟悉运用git指令管理和开发项目，构建CI CD；熟悉AWS相关产品设置和使用
- 有区块链相关开发项目和经验，熟悉Zcash、Horizen、Filecoin区块链等开发技术；

项目经验

2021-10 ~ 2022-01	宝山区消防作战辅助决策系统	项目工程师—前端
技术选型：vue3、Spring Boot、MyBatis、MySQL		
项目描述：该项目主要提高消防队作战效率，案情发生时，通过web端发送案情指挥，协调作战。主要实现了用户管理模块、预案推送模块，消息显示与匹配模块等微服务模块；使用Vue+Element UI框架开发项目前端界面，用户登录，预案信息的多重展示，预案信息的匹配和推送等功能。		
2022-02 ~ 至今	科技部国家重点研发计划项目（涉密）	技术开发人员—算法
项目描述：研究网络的匿名性和传输机理，设计抗溯源跨境网络应用平台		
项目职责：因项目涉及相关国家利益，需要对项目开发内容和开发流程进行保密。		

实习经历

2023-05 ~ 2023-08	软通动力有限公司（外派阿里云）	大模型推理优化实习生（大模型方向）—算法
• 技术：python、c++、PyTorch、docker		
• 参与阿里云震旦异构平台相关推理性能优化、编译优化等高性能开发工作；了解Megatron、FastTransformer等框架		
• 参与大模型的推理优化与加速，部署分布式环境、进行分布式推理；调研和整理目前大模型推理优化前沿论文；		
• 参与模型编译优化算子的生成与验证，参与引擎优化工作，包括算子、计算图优化等工作。		
2021-06 ~ 2021-08	嘉兴市南湖实验室	大数据操作系统开发员—后端
• 技术：Scala、对象存储、数据湖（delta lake）		
• 职责：协助湖仓一体数据湖洞察系统开发、设计对象存储接口与 delta lake 的相互传输；		
• 实现数据湖存储管理和系统监控功能，支持多元异构数据；通过spark和flink不同计算引擎流入湖，统一访问湖内数据。		

奖项荣誉

研究生期间：		
• 校研究生联合会文艺部部长、学院学术部干事、连续两年获得校级奖学金、2022学年荣获一等奖学金		
• 百川智能x亚马逊云科技黑客松大赛，入围大模型娱乐赛道30强		
• 荣获2021-2022学年优秀学生干部、校级优秀学生、优秀志愿者称号；2024学院优秀毕业生		
• 曾获2021年全国“华为杯”数学建模竞赛三等奖、2022年全国“华为杯”数学建模竞赛三等奖		
本科期间：		
• 曾任中国计量大学助理班主任、信息工程学院党员之家办公室主任、社团联合会外联部干事、益微青年支教成员		
• 曾获得2018-2019、2019-2020学年浙江省政府奖学金、荣获浙江省优秀毕业生、校级优秀毕业生		
• 连续四年获得校优秀学生奖学金、多次获得优秀学生一等奖学金		
• 第九届“挑战杯”大学生竞赛校一等奖、2020年浙江省大学生高等数学竞赛一等奖、全国大学生数学竞赛浙江区一等奖		

自我评价

爱好：健身、篮球、摄影师、旅游徒步、动漫、八段锦。	详情： www.carpediemyang.cn/hobby
性格：	
• 踏实：工作和学习之中只有认真踏实做事，才能做好；学习能力：有一定的学习新事物能力，才能不被淘汰。	
• 热情：对于自己感兴趣的事，有着无限动力去实现；生活上积极向上，开朗阳光，能够快速融入工作和学习环境；	