

程遥

19371841904 | 1647560307@qq.com | 上海



工作经历

上海寻梦信息技术有限公司

2023年12月 - 2025年04月

服务端开发工程师 研发部-平台治理

上海

核心项目

亿级商品治理策略平台，负责策略平台开发和维护，支持实时增量检测与批量存量计算，日均处理1亿+商品数据，策略任务并行计算量达1万+/日。实现运营配置-计算-处罚自动化，替代50%+人工审核，平台处罚、打标量超平台治理总量50%；

性能优化专项

- 设计规则预筛+缓存机制，减少70%无效计算，全量任务耗时从14h压缩至8h，节省40%服务器资源；
- 通过聚合消息+增量变更过滤器，基于事件驱动精准触发策略计算，消息消费延迟从30min降至5min，解决实时消息堆积问题；
- 设计立即执行功能，结合Redis计算实时熔断值，超阈值后降级为小时级任务，关键处罚延迟从1小时压缩至5分钟；

风控与稳定性保障

- 开发熔断降级系统，实时拦截超阈值任务（如高gmv、大批量执行），日均拦截风险任务1k+；
- 设计分页拉取+异常隔离执行引擎，异常数据自动降级至死信队列，保障95%正常任务实时生效，日均处理量达100w+；
- 把熔断-工单审批-执行流程整理为影响面系统，为平台治理内多个业务组提供风控保障，已有5个业务方的100+任务接入，单日执行量100w+；

上海寻梦信息技术有限公司

2023年05月 - 2023年12月

服务端开发工程师（AI推理方向）研发部-平台治理

上海

- 负责BERT等模型推理优化，基于TensorRT（GPU）与OpenVINO（CPU+GPU）构建部署方案，适应不同硬件资源的场景，模型刷库速度提高30%；
- 设计通用化推理框架，封装数据加载、预处理、多阶段模型推理、后处理流程，标准化算法团队开发接口，降低模型部署成本，提高资源利用率；
- 结合Nsight定位计算瓶颈，使用FasterTransformer封装decoder层，单卡LLAMA推理提速15%；

技术技能

- 编程语言：Java、Python、c++
- 熟悉torch框架，了解基于Transformer的常见模型架构
- 有TensorRT、OpenVINO、ONNX等推理框架，和Polygraphy、Nsight等调试工具使用经验
- 了解LLM基础优化技术FlashAttention、PagedAttention、KV Cache等
- 其他：Linux常用指令、英语CET-6

教育经历

南京航空航天大学 211 双一流

2020年09月 - 2023年04月

控制科学与工程 硕士 自动化学院

南京

研究生一等奖学金（Top 5%）

南京航空航天大学 211

2016年09月 - 2020年06月

自动化 本科 自动化学院

南京

自我评价

- 逻辑严谨，能快速定位复杂系统问题
- 愿意了解业务，需求开发中能够结合具体业务特点设计方案
- 关注技术发展，乐于学习新技术