

贾浩 | 18817285996 | jh.haojia@gmail.com

WORK EXPERIENCE

Senior Engineer | Wiener Intelligence

Oct 2024 – Feb 2025

- 应用低秩适配 (LoRA) 技术对基于 LLaMA 的大语言模型在特定领域语料上进行高效微调, 显著降低训练参数规模与 GPU 显存占用。
- 基于 vLLM 部署微调模型, 实现高吞吐、低延迟的推理性能, 并通过 FastAPI 构建 RESTful 接口集成至内部服务系统。
- 带领 5 人团队设计并开发模块化后端平台, 支持 RAG 问答机器人与 AI 写作助手, 涵盖系统提示生成、引用感知重写与多轮对话记忆管理, 大幅提升模型适应性与响应连贯性。
- 构建 Prompt 评估框架, 自动衡量 LLM 输出的连贯性、流畅度与事实准确性, 实现在线监控与自动化评估, 生产准确率超过 98%。
- 利用 Docker、Redis、Celery 构建稳定的机器学习基础设施, 支持异步任务编排与 Webhook 调用, 集成 Prometheus 与 Grafana 实现全链路监控与告警, 保障系统稳定性与可观测性。

Software Engineer | TikTok | E-Commerce | Mountain View, USA

Aug 2022 – Jul 2024

- 基于消息队列构建支持十亿级吞吐的异步数据处理平台, 实现实时数据同步、高效数据转换, 并无缝接入模型训练与产品分析链路。
- 主导开发基于大语言模型 (LLM) 的 AI 购物助手, 支持自然语言理解与意图对齐的直接问答, 显著提升搜索满意度与用户互动效率。
- 实现融合语义检索与 LLM 的 RAG 系统, 支持跨异构数据源的信息检索、排序与生成整合, 增强响应的个性化与内容质量。
- 与机器学习工程师协作设计并部署模块化推荐系统, 覆盖商品召回与排序, 基于嵌入相似度进行优化, 用户留存率提升达 20%。

Machine Learning Engineer Intern | 小红书

Jan 2022 – Mar 2022

- 在自然语言处理团队开展多模态内容理解, 优化信息流排序与推荐效果。
- 通过改进特征融合方法、设计跨文本与图像的预训练任务, 开发并优化多模态机器学习模型, 支持大规模 CV/NLP 生产系统落地。

Software Engineer Intern | Alibaba Cloud

Jul 2021 – Dec 2021

- 在阿里云基础设施服务团队, 在虚拟化 GPU 环境中使用 DeepSpeed 加速大规模模型训练, 优化显存占用, 并实现跨容器的高效多任务训练。
- 构建基于 Kubernetes 的虚拟化系统, 设计 RESTful API, 实现深度学习应用的自动部署、弹性扩展与生命周期管理。

SKILLS

- **Programming Languages:** Python, Golang, C++/C, JavaScript, Java, SQL, Gremlin
- **Frameworks & Tools:** PyTorch, TensorFlow, Distributed Computing, LangChain, Hugging Face, Vector Database, AWS, Docker, Kubernetes, MySQL, MongoDB, Redis, Kafka
- **Domains:** LLMs, Ads & Recommendation Systems, Multimodal Learning, Embedding, Search & Retrieval, Distributed Systems, RAG, Prompt Engineering

EDUCATION

Bachelor of Science in Computer Science

Oregon State University (GPA: 3.75/4.0)

Corvallis, OR

Sep 2018 – Jun 2022