



肖晗

电话: 17356509786 | 邮箱: Xh544023@outlook.com | 现居城市: 合肥

个人网站: <https://github.com/eleven-day>

当前状态: 离职 | 意向城市: 合肥 | 求职意向: AI应用开发 | 期望薪资: 28k-30k



哈尔滨工业大学

教育经历

哈尔滨工业大学 - 经济学 本科 法学与人文社会学院

2017年09月 - 2021年07月

985 双一流

1.主修课程:

• 概率论与数理统计,经济数学模型,计量经济学,数据分析与挖掘,运筹学等

2相关课程:

• 线性代数,高等数学,统计学,计算机编程,Python,数据结构与算法

专业技能

- 编程与框架: 精通 Python、FastAPI、Express.js 构建高性能异步API; 熟练掌握 SQL、Node.js; 熟悉 SQLAlchemy 等ORM框架; 具备 C++ 基础。
- 大模型与AI应用: 熟悉 Llama、Mistral、Gemini、NLLB-200 等模型应用; 精通 LangChain、LlamaIndex 构建 RAG 与 AI Agent; 具备系统化提示词工程能力; 熟悉知识图谱构建 (HanLP, NetworkX)。
- 模型优化与推理: 熟悉 vLLM、TensorRT-LLM、TGI 等高性能推理框架; 掌握 BitsandBytes (QLoRA)、AutoGPTQ 等量化技术, 熟悉 GGUF (Llama.cpp) 格式, 擅长优化模型在CPU及资源受限环境下的运行效率。
- 多模态技术: 精通 OCR 及 VLM 技术提取结构化信息; 熟悉人像抠图 (ModelScope) 与图像增强 (ComfyUI); 熟练运用 FFmpeg 处理音视频, 掌握 FunASR、Whisper 等ASR技术, 具备文本到视频 (TTS + Wav2Lip) 应用开发经验。
- 数据与中间件: 熟练使用 MySQL、PostgreSQL; 熟悉 Redis 的缓存与消息队列应用; 精通使用 Celery、asyncio.Queue 构建异步任务系统; 熟悉 Milvus、Faiss 等向量数据库。
- DevOps与云服务: 精通 Docker 与 Dockerfile; 熟悉 Kubernetes (K8s) 服务部署; 熟悉 Jenkins/GitLab CI 构建CI/CD流水线; 熟练运用 Linux Shell; 精通 Prometheus + Grafana 搭建监控告警系统, 及 SkyWalking 进行链路追踪。

工作经历

广州蜗牛保险经纪有限公司-AI算法工程师 AI中台与创新应用部

2024年05月 - 2025年06月

- 主导公司AI应用服务化生态的从0到1建设, 围绕大语言模型和多模态技术, 设计并开发了十余个核心AI微服务, 为多个业务线提供了标准化、高可用的AI能力。
- 负责AI原生应用的全链路开发, 从需求分析、技术选型、架构设计, 到模型集成与优化、后端开发、容器化部署及线上维护, 积累了丰富的端到端项目落地经验。
- 攻克多项技术难题, 如超长文本的高效处理、复杂文档的结构化信息提取、第三方Web应用的自动化控制等, 通过创新的技术方案, 显著提升了数据处理效率和业务自动化水平。

北京东方国信科技股份有限公司-算法工程师 数据挖掘中心

2021年07月 - 2024年03月

- 参与核心电信AI算法平台研发, 负责用户流失预测、智能推荐等场景的算法建模与工程化, 通过特征工程与模型调优, 累计提升核心业务指标25%。
- 主导开发向导式自动化建模功能, 利用 PyTorch (LSTM, NeuralProphet) 实现时序预测, 将模型部署周期缩短70%, 并率先引入 RAG 技术奠定团队大模型应用基础。

项目经历

端到端AI知识视频生成系统 (AI-Video-Generator)-AI全栈

2025年03月 - 至今

- 职责与成果: 为解决传统视频制作流程繁琐、成本高昂的问题, 主导设计并实现了从主题到成片的全自动化AI视频生成器。利用 Google Gemini API 和提示词工程生成结构化脚本, 集成 Azure TTS 合成配音, 并创新性地采用 Playwright 自动化操作第三方 Web应用生成视觉PPT。最终通过 FFmpeg 精准合成音画, 将视频制作周期从数天缩短至45分钟以内。

多模态内容理解与信息提取系统 (multimodal2text)-AI算法工程师 AI中台与创新应用部

2025年07月 - 2024年12月

- 职责与成果: 为解决业务中异构数据处理难题, 从0到1主导设计并研发了公司级多模态内容处理中台。将服务解耦为同步、异步、ASR三个微服务, 并基于 LangChain 与 VLM 开发了针对音视频、文档的核心处理器, 创新性地引入语义路由机制。通过精细的资源控制与熔断设计, 保障了服务高可用性 (99.5%), 将新业务的AI能力接入成本降低40%。

个人总结

- 近三年 AI 应用全栈开发经验, 主导和核心参与了公司从0到1的AI服务生态构建, 具备独立负责AI原生应用的架构设计、开发、部署与维护的全链路能力。
- 精通以 LLM/VLM 为核心的应用开发, 在 RAG、Agent、多模态内容理解、知识图谱构建等方向有丰富的实战经验和深刻的技术洞见。
- 具备扎实的后端工程能力, 熟练运用 Python、FastAPI、Docker、Kubernetes 等技术构建高可用、可扩展的微服务架构, 并精通 Prometheus、SkyWalking 等监控与可观测性工具。
- 对AI应用性能优化有深入理解, 熟悉 vLLM、模型量化(GGUF/GPTQ)、异步任务队列(Celery/Redis) 等技术, 擅长在资源与性能间寻求最优解。
- 技术热情驱动, 具备出色的问题分析与解决能力, 能快速响应业务需求, 将前沿AI技术落地为高价值的商业应用。