

张凯歌

(+86)136-2426-2268 | edith_zhang@outlook.com

个人信息

个人博客: [aaricis.github.io](#) | Github: [Aaricis](#)

目标岗位: xxx | 意向城市: 上海 / 杭州

技能清单

- 研究方向: AI+情感陪伴、AI for System性能优化, 熟练阅读英文文献;
- 算法能力: 了解Transformer、BERT、Diffusion模型及SFT、RLHF;
- 工程实践: 熟悉Python、Java大型项目开发及常用数据结构和算法, 具备复杂系统设计与优化能力;
- 框架工具: 熟练使用PyTorch、SpringBoot、MyBatis; 熟悉Git、Linux、Redis等常用工具和环境;
- 大模型与系统优化: 具备LLM推理优化、并行策略搜索、系统级调优平台开发经验;

工作经历

个人成长与探索

2024年11月~至今

- 技能提升: 系统学习深度学习、生成式AI及大模型应用开发相关知识 ([学习分享专栏](#));
 - 完成李宏毅《Introduction to Generative AI》、《Machine Learning》, 吴恩达《面向开发者的LLM》等6门课程;
 - 斯坦福《CS336: Language Modeling from Scratch》学习中;
- 创业尝试: 通过提升情商使人工智能模型人性化, 提供深层次的情感陪伴;
 - 评估大语言模型(Gpt、Llama、Qwen等)的情商, 广泛调研现有AI+情感陪伴/心理/疗愈产品;
 - 个人AI+情感陪伴项目开发中, 致力于多模态情感理解。

华为 | AI for System研究员 (Research & Development)

2023年4月~2024年11月

- 参与AI智能调优技术研究, 负责技术洞察、方案设计与验证及技术落地;
- 基于约束贝叶斯优化, 研发大模型训练多维并行计划求解器Tinker, 较暴力搜索仿真轮次削减3-4个数量级, 60s内可达理论最优;
- 参与A+K算力异构协同技术预研, 设计A+K算力分发子系统, 实现基于黑盒代价模型与智能决策算法的计算图自动分发/映射引擎;

华为 | Java后端开发工程师

2021年8月~2023年4月

- 参与MetaCRM Foundation的研发, 负责公共数据、企业协同的设计开发和运营;
- 参与MetaCRM架构统一、性能加速重点方案研讨, 负责公共数据高性能加速通道方案设计开发;
- 主导MetaCRM公共数据域的重构工作, 去除冗余接口21个, 减少代码仓4个, 降低代码量2w+;
- 负责解决产品技术债, 包括统一编码规范、提高测试覆盖率、项目架构统一等工作。

项目经历

AI for Systems研究项目 (2023年4月~2024年11月)

AI for System研究员

项目名称: 通用计算基础软件智能调优

项目背景: 基础软件如MySQL、Flink、Spark等拥有众多的配置参数, 默认的参数配置往往不能发挥出最佳的应用性能。依靠专家经验调整参数值来优化性能, 面临参数组合爆炸、人工分析成本高、负载迁移性差等问题。AITuner使用AI驱动的迭代优化方法, 以最小的工程代价实现基础软件性能自动优化。

工作内容/个人职责:

- 利用贝叶斯优化替代专家经验, 实现配置参数的自动采样与多层级系统调优, 从应用到操作系统实现深度性能优化。开发自动化通用调优引擎, 将调优时长从数天降至数小时; 在大数据场景 (Spark+OmniRuntime、Hive、Flink) 下性能提升14%-33%, 在数据库场景 (MySQL+OpenEuler) 下性能提升8%-18%。

2. 使用基于模型的曲率插值优化技术，从压测曲线的初始阶段推断出最终的性能值，从而加速数据库调优速率，在 openGuass场景可获得3x的加速比；
3. 负责AITuner调优平台的架构设计和产品化交付，负责参数解调器、调优器等7个模块的设计开发。

项目名称：Tinker并行策略求解器

项目背景：大模型已被广泛应用在各个领域，但训练数十亿到万亿的参数是具有挑战性的。面对最大化训练效率的要求，分布式训练是必经之路。为减少工程负担、快速迭代和实验、探索下一代集群架构，湛卢平台衍生出自动并行策略搜索/优化需求。Tinker为并行策略优化模块，用于高效搜索大模型分布式训练任务的最优并行策略，实现集群计算性能的最大化使用。

工作内容/个人职责：

1. 针对高维复杂的并行训练策略参数空间，设计并实现结合约束学习的泛贝叶斯优化方法，大幅减少采样次数至千次级。通过引入专家知识进行白盒空间剪枝，有效配置比例由10%提升至70%；同时结合拉格朗日乘子法构建灰盒约束学习机制，提升搜索器在隐形约束下的收敛效率与精度，实现分钟级高效并行策略优化，显著提升大模型训练性能与稳定性。
2. 支持万亿模型万卡AI自动并行策略分钟级快速优化；支持5D并行以及业界范围重要并行训练优化手段的决策；基于黑盒学习的优化器核心，具有良好的扩展性。
3. 负责Tinker并行策略求解器的产品化交付。

项目名称：A+K异构算力协同

项目背景：NPU架构对高精度浮点运算，稀疏访存等有性能缺陷。相较于GPU，NPU无法满足日益演进的AI计算类型。面临GPU的技术和商业垄断，AI突围需从NPU卸载范式转向CPU+NPU协同范式。AI框架自动评估模型算子对Kunpeng和Ascend的硬件架构的亲性和，自动分发算子，实现最优架构互补，最大化发挥异构算力。

工作内容/个人职责：

1. 基于 PyTorch 框架构建 K+A异构算力分发系统，自动评估模型算子对 Kunpeng 与 Ascend 架构的亲性和，实现协同计算。改造 Baechi 的 m-ETF 调度算法以支持 CPU+NPU 异构资源，设计 Execution Simulator 生成分发策略，并通过 wrapper 封装方法将策略集成至模型运行流程，实现运行时跨设备 Tensor 动态迁移，提升系统整体资源利用率与计算效率。
2. 在图神经网络（GCN）场景下，POKA的概念原型系统(基于专家规则分发映射)基于K+A对比K-only和A-only性能提升一个数量级。

MetaCRM Foundation（2021 年 8 月 ~ 2023 年 4 月）

Java 后端开发工程师

项目背景：为了满足MetaCRM系统中数据管理、安全隐私、企业协同等共性需求，CRM Foundation作为MetaCRM的公共底座与运行时所依赖的公共服务，为整个系统提供公共数据、公共能力和增值业务能力。

涉及技术：Spring Boot、Spring Batch、Mybatis、Redis、MongoDB、领域驱动开发、微服务

工作内容/个人职责：

1. 负责MetaCRM公共数据管理面和客户面开发，提供统一的公共数据管理及访问加速；
2. 使用消息队列MQS推送源端增量公共数据，实现公共数据实时更新，并且用户无感知；
3. 自顶向下梳理公共数据业务场景，设计Redis Key生成规则，生成Key 1000万+，并使用GaussDB Redis缓存热点数据，将查询响应时间从分钟级降至<20ms，提升用户体验；
4. 作为企业协同模块Owner，负责需求分析和总体架构设计，协调前端同事完成任务管理、通知消息、邮件沟通等模块的开发，构建MetaCRM增值业务；
5. 参与MetaCRM架构统一重点方案研讨，基于领域驱动设计和元数据多租驱动的微服务，设计统一的参考架构并推广落地，实现MetaCRM升级重构。

教育经历

大连理工大学 计算机应用技术，计算机科学与技术学院 学术型硕士研究生	2018.9—2021.6
研究方向：强化学习，在多智能体强化学习方向有一定的研究和工程经验；	
主要研究成果：论文《Pheromone Based Independent Reinforcement Learning for Multiagent Navigation》发表在NCAA 2021。	
大连理工大学 计算机科学与技术，计算机科学与技术学院 工学学士	2014.9—2018.6
GPA: 3.6/4.0(专业前15%)，免试攻读研究生。	